Amazon公开数据分析项目

结项报告

数据预处理、可视化、文本分析与推荐实验

姓名：胡泽雅（Zeya Hu）

项目周期：2026年10月8日至11月4日

结果整理日期：2026年11月3日

本报告总结了四周已完成的学习与项目任务，包括数据分析、模型实验、业务建议、工程整理、成果展示及演示视频。

正文超过8,000字，结合统计表、图表和具体样例说明四周的主要工作。

目录

一、项目目标与整体完成情况 3

二、数据范围、分析单位与使用边界 3

三、第一周：数据质量检查与预处理 4

四、第二周：标准化结果与商品分析 5

五、历史评分、文本结构与可视化看板 8

六、情感分析：阈值改变了哪些结论 9

七、第三周：主题模型与随机种子比较 11

八、推荐实验：数据划分、评分预测和原型 12

九、热门推荐为什么优于SVD：目标、候选集与长尾 14

十、第四周：从低评分筛选到具体商品证据 15

十一、业务行动建议与后续观察方式 17

十二、工程整理、复现验证与学习总结 18

结果依据与文件索引 20

阅读提示：第一至五章说明数据基础与可视化；第六至九章讨论文本和推荐模型；第十至十二章记录商品业务分析、行动建议及工程验证。

一、项目目标与整体完成情况

这四周，我按照老师提供的任务安排，分析了Amazon商品资料、历史评分和评论文本。项目周期为2026年10月8日至11月4日。刚开始时，我对机器学习和实际数据处理还不熟悉，所以先从读取文件、看懂字段和处理报错做起，再逐步完成图表、文本分析和推荐实验。每完成一步，我都会核对输出并保存结果。到项目后期，我开始更关注结果为什么会这样，以及这些结果能够说明什么。

第一周完成了原始文件检查、字段识别、缺失与异常处理、商品去重、历史评分去重及汇总。第二周根据老师反馈补充了数据字典、缺失值统计表和异常值检查表，分析商品类别、价格、评分、折扣及历史评分变化，并完成评论关键词、情感分析和Power BI看板。第三周尝试了LDA主题模型、SVD评分预测及推荐原型，并进一步比较不同随机种子、商品热门程度和候选集设置。第四周将前面的发现落实到具体商品阅读清单、反馈归纳和行动建议，同时整理代码工程与运行说明。

截至2026年11月3日，四周计划中的任务均已完成。我完成了数据预处理、可视化、文本与推荐模型实验、商品评论阅读和业务建议，也整理了结项报告、总结PPT、周报、GitHub工程和演示视频。本报告把各周工作连在一起，说明我做了什么、发现了什么，以及根据老师反馈作了哪些修改。商品改进建议是本项目的分析产出，实际产品检测和商家整改不属于本次已执行的工作。

做完项目后，我对数据分析有了三个比较直接的认识。首先，清洗数据之前要弄清楚一行代表什么，不能看到重复或空值就直接删除。其次，模型复杂不代表结果一定更好，还要看比较的方法和评价指标。最后，提出建议时要能找到对应的表格或评论，遇到不同意见也要一起考虑。对我来说，这次练习不只是把程序运行出来，更重要的是学会解释结果，并把分析过程整理清楚。

二、数据范围、分析单位与使用边界

2.1 两份原始文件分别记录什么

历史评分文件ratings_Electronics (1).csv共有7,824,482行、4列，分别是用户编号、商品编号、评分和时间戳。它没有表头，也没有评论正文。每一行表示一条用户对商品的评分记录，而不是一笔订单。评分数据中共有476,002个不同商品。商品编号必须按字符串读取，例如开头带零的编号，如果按数字处理会失去原始形式，进而影响匹配和去重。

另一份amazon.csv共有1,465行、16列，包含商品编号、名称、类别、折后价格、原价、折扣、商品汇总评分、评分人数、商品介绍及评论相关字段。价格带有印度卢比符号，评分人数带有千位分隔符。类别字段使用竖线表示层级，因此可以提取第一层作为主要类别。该表虽然在项目资料中被称为销售数据，但实际字段中没有购买数量、订单金额、成本或库存，不能仅凭文件名称把评分人数当作销量。

商品表中的rating是商品层面的汇总评分；历史文件中的rating是一条用户评分。两者都使用五分制，但统计单位不同。对商品评分取平均时，每个商品获得相同权重；对历史评分取平均时，每条评分获得相同权重。同样，商品表附带的评论正文往往把多段评论放在一个单元格中，因此一行商品也不能简单等

同于一条独立评论。这些区别贯穿后续统计、文本解释和推荐评估。

2.2 为什么没有强行合并两份数据

实际检查发现，两份数据只有6个共有商品，占商品表1,351个不同商品的约0.44%，对应历史评分4,308条。这样的重合程度不足以支持把两张表拼成覆盖完整商品和用户的统一交易数据。项目保留了一个小范围关联示例，但商品描述分析与历史评分推荐实验主要分别开展。这样可以避免关联后仅剩极少商品，却仍把结果解释为整个数据集的情况。

历史评分的时间范围是1998年12月4日至2014年7月23日，采用UTC时间。商品表没有可用于统一对齐的完整采集日期，因此不能把商品价格和历史评分当作同一时间点的信息，也不能据此研究价格变化如何影响用户评分。历史年度曲线描述的是该文件收录的评分活动，不是Amazon全部业务的发展曲线。特别是边界年份的记录不完整，直接比较年度总量容易产生误解。

根据现有字段，我能够分析商品类别、价格、评分和评论，也能尝试历史评分推荐。但我没有订单、曝光、库存或成本数据，所以回答不了促销增加了多少销量、哪些用户消费最多、应该补多少库存等问题。实际做过匹配检查后，我才更清楚地认识到：先看数据里有什么，再决定能研究什么，比一开始就设定很多业务指标更合适。

三、第一周：数据质量检查与预处理

3.1 建立可追溯的数据处理流程

第一周先读取少量记录确认文件结构，再采用分批读取处理较大的历史评分文件。分批处理可以控制内存占用，但每批检查之后仍需要累计总记录数、缺失数量和异常数量，不能只凭前几行看起来正常就判断整份文件没有问题。各阶段保存单独输出，原始文件保留，便于发现问题后回到前一步检查。通过原始行号，也能够追踪清洗结果来自哪条输入记录。

对历史评分，我检查了用户和商品编号是否缺失、评分是否能转为数字且处于一至五分之间，以及时间戳能否正确转换。最终7,824,482条记录均通过检查，未发现缺失或异常评分，时间转换异常数量也为零。清洗表与问题记录表的数量进行了核对，清洗后记录数与原始记录数相同。这里的“没有发现问题”指本项目采用的规则检查通过，不代表数据已经经过所有可能的质量验证。

历史评分的完全重复检查使用本地SQLite数据库完成，以便跨批次比较整份数据。最终删除的完全重复记录为零，去重后的记录数仍为7,824,482条。随后按商品汇总评分条数、不同评分用户数、平均评分和低评分比例，汇总后的评分总量再次与输入核对一致。这样既得到后续分析可以使用的商品汇总表，也避免只在单个批次内去重而遗漏跨批次重复。

3.2 商品缺失、异常与重复记录的处理

商品表中发现一条rating为竖线字符，不能解释为有效分数；另外两条rating_count缺失。清洗时将非法评分转为缺失值，评分人数缺失仍保留为空，没有用零代替。零意味着实际观测到没有评分，缺失则意味着不知道，这两种情况含义不同。如果把缺失评分填成零，还会人为增加低评分商品数量，影响后续筛选。因此，相关分析只在有效值范围内计算，并明确报告分母。

价格字段删除货币符号和千位分隔符后转为数字，货币单位保留为INR。折扣从百分数字符转为零到一之间的比例，例如0.64表示降价64%。检查内容包括原价是否大于零、折后价是否为负、折后价是否超过原价、折扣是否越界，以及价格计算出的折扣与展示折扣是否相差超过一个百分点。该数据在这些检查中没有被标记的价格或折扣记录，但这并不证明展示原价一定等于真实市场成交价。

商品编号有重复，但整行完全重复数量为零。原始表中有92个商品编号出现多次，涉及206行，比每个商品保留一行多出114行。其中33个商品在选定关键字段上存在差异，例如评分人数、原价或折扣比例不同。这些重复可能涉及不同记录版本或文本内容，不能只删除后就忽略差异。本项目保存完整清洗表，同时为重复商品输出检查清单，便于后续追踪。

每商品一行的分析表按原始行号保留首次出现的记录，最终得到1,351行。选择首次记录是一个明确且可复现的处理规则，并不表示首次记录是最新或最准确的记录。分析表保留原始记录数、差异字段、是否存在关键差异及选择规则。第四周筛选时又使用这些标记，将需要优先核对关键差异的商品单独分组，说明第一周的质量信息确实参与了后续业务分析。

四、第二周：标准化结果与商品分析

4.1 数据字典和质量检查表

老师认为第一周的预处理没有问题，但建议把结果整理得更标准。我补充了数据字典，说明原始表和主要分析表中各字段的含义、类型、单位，以及每一行代表的内容，共整理了六张表、52条字段说明。整理时，我也重新区分了商品评分、历史用户评分和情感得分。虽然这些字段都与“评分”有关，但计算和使用方式并不一样，这份字典方便我后续查阅。

缺失值统计同时展示原始商品表、完整清洗表和每商品一行分析表。清洗前rating缺失为零，清洗后变为一条，是因为非法字符被识别为缺失，并不是清洗过程丢失了一条有效分数。评分人数的两条缺失在清洗前后保持一致。把这种变化单独列出来，比只报告清洗后缺失数量更容易解释处理逻辑，也能避免将“缺失数量增加”误认为清洗质量下降。

除了格式和取值范围检查，我还使用四分位距方法标记统计极端值。商品价格有209条、评分人数有130条被标记。极端值并不自动等于错误：电子产品可能本来就价格较高，热门商品也可能拥有更多评分。因此这些记录仅被标记，没有直接删除。后续价格分析同时使用中位数、分位数和对数坐标，从展示方式上处理偏斜，而不是为了让图形整齐而删除真实差异。

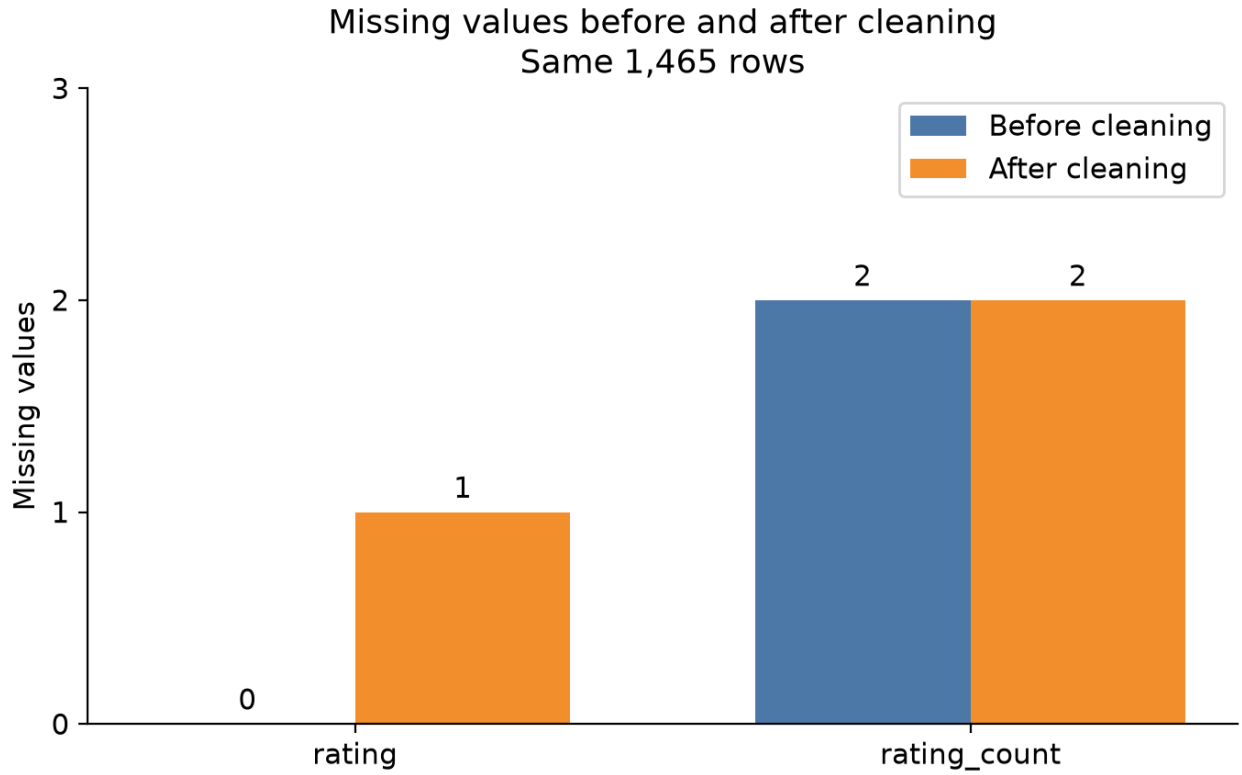


图1 商品清洗前后缺失数量：非法评分转为空值后，评分缺失增加一条。

4.2 商品类别与价格结构

商品样本共有九个主要类别，其中电子产品490个，占36.27%；家居厨房448个，占33.16%；电脑及配件375个，占27.76%。三个类别合计占约97.19%，其余类别规模明显较小。办公用品有31个商品，部分其他类别仅有一至两个商品。整体结果主要反映前三个类别，因此小类别中出现较高或较低平均分时，应同时看样本量，不能据此给所有类别作稳定排名。

全部商品折后价格平均值为3,304.80卢比，中位数为899卢比，最高为77,990卢比。平均值明显高于中位数，说明少数高价商品对平均水平影响较大。百分之九十的分位价格为8,990卢比，百分之九十五为16,249卢比，进一步显示价格跨度较大。对于样本中常见的商品价格水平，中位数比单独使用平均值更直观，但它也不能替代具体商品之间的规格比较。

三个主要类别的价格中位数分别是电子产品1,384卢比、家居厨房1,199卢比、电脑及配件399卢比。电子产品内部价格跨度也更大。类别价格表补充了最小值、四分位数、均值和最大值，使读者不仅能知道某类商品大致贵不贵，还能看到类内差异。实际定价仍需考虑品牌、规格、用途和成本；本项目没有这些完整条件，因此没有给出具体涨价或降价幅度。

Discounted price by category (INR)

Category	Valid n	Min	Q1	Median	Mean	Q3	Max
Electronics	490	79.00	399.00	1,384.00	6,225.87	7,998.75	77,990.00
Home&Kitchen	448	79.00	632.50	1,199.00	2,330.62	2,695.75	42,990.00
Computers&Accessories	375	39.00	249.00	399.00	947.49	849.00	37,247.00
OfficeProducts	31	50.00	117.00	178.00	301.58	380.50	1,399.00
MusicalInstruments	2	478.00	558.00	638.00	638.00	718.00	798.00
HomeImprovement	2	249.00	293.00	337.00	337.00	381.00	425.00
Toys&Games	1	150.00	150.00	150.00	150.00	150.00	150.00
Car&Motorbike	1	2,339.00	2,339.00	2,339.00	2,339.00	2,339.00	2,339.00
Health&PersonalCare	1	899.00	899.00	899.00	899.00	899.00	899.00

Q1/Q3: 25th/75th percentiles. Categories with very few products are descriptive only.

图2 各类别价格统计表。单位为印度卢比，类别样本量需与价格指标一起阅读。

4.3 评分与折扣需要分开理解

1,351个商品中有1,350个有效评分，平均约4.092分，中位数4.1分。评分达到四分及以上的商品有1,010个，占有效评分商品的74.81%。四分至低于四点五分的商品数量最多，说明整体汇总评分集中在较高区域。不过，商品平均分可能掩盖具体功能或使用场景中的负面反馈，因此不能仅凭总体均值较高，就认定所有商品都没有改进空间。

按照老师建议，我补充了按类别拆分的评分分布。电子产品四分及以上占73.88%，家居厨房约67.79%，电脑及配件82.40%。家居厨房有一条评分缺失，因此比例分母为447个有效评分商品，而不是全部448个商品。这个结果提供了进一步阅读商品反馈的方向，但不能证明类别本身导致评分较低；类别内商品用途、价格及样本选择都可能影响比较。

商品展示折扣平均约46.685%，中位数49%。按零至低于百分之二十、二十至低于四十、四十至低于六十、六十至低于八十、八十至一百分组，商品数分别为162、316、449、343和81。这里使用最终统计表中的分组结果。较高折扣只是展示价格相对原价的差额，不等于真实便宜程度，更不能直接推出促销提高销量或利润。项目没有订单和成本数据，所以折扣分析停留在描述层面。

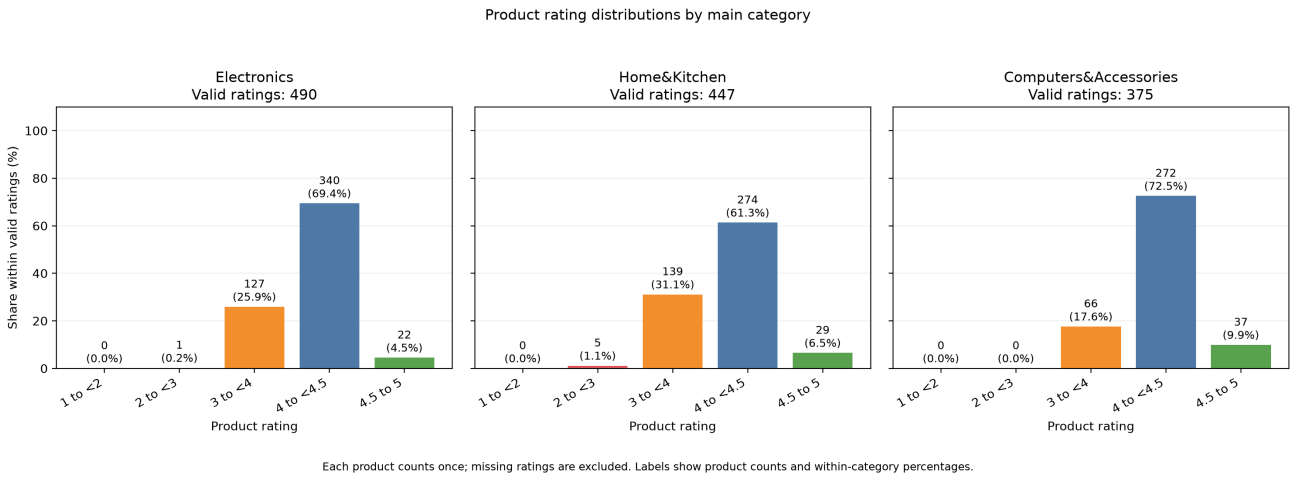


图3 按类别拆分的商品评分分布，补充整体评分直方图无法呈现的类别差异。

五、历史评分、文本结构与可视化看板

5.1 历史评分活动

历史评分中五分记录占55.56%，四分占18.99%，一至二分低评分合计占17.36%，全部记录平均为4.0123分。年度评分量在后期增加，2013年有2,626,582条，2014年有1,708,604条。但2014年的数据只到七月，不能直接依据年度总数较少就判断评分活动下降。1998年也只有边界时间内的少量记录，年度均值的解释需要结合记录数。

年度图用于观察样本覆盖范围与评分活动变化，不能把它改称销售额走势图。相同的平均评分也可能来自不同的评分分布，因此我同时保存年度平均分、低评分比例和评分数量。数量、水平和分布放在一起，能够减少只看单一曲线的误判。看板中总体平均分按评分总和除以评分总数计算，不对各年度均分再简单平均，否则小年份和大年份会获得不合理的相同权重。

5.2 评论文本为什么按整格分析

商品分析表对应的1,351个评论正文均非空，仅统一空白后的不同正文有1,197份，进一步清理后有1,186份。评论编号字段在1,347个商品中包含逗号，正文中也混有自然语言逗号、链接和多段反馈。由于无法保证评论编号、标题和正文之间逐条可靠对应，我没有直接按逗号拆分。后续的文本长度、关键词、情感和主题分析以整格文本为单位，并在需要时去除完全相同正文。

清理后的整格文本长度中位数为800个字符，最长18,507个字符。长度与商品评分的Spearman相关系数，在全部有效配对商品中为0.1163，在不同清理文本对应的样本中为0.1027，均为较弱的正向关系。这不意味着写得越长就越满意，因为长度还受到合并评论数量、用户表达习惯和商品类型影响。该分析主要用来认识数据结构，而不是建立文本长度决定评分的解释。

关键词统计中，good出现在1,136份不同文本中，quality出现在752份，price出现在589份。这里的出现文本数与总词频不同：一个词在同一文本反复出现，总出现次数会增加，但文本覆盖只增加一次。关键词柱状图便于比较数值，词云便于快速浏览常见表达。两者都不能直接说明问题原因，因为“质量好”和“质量差”都可能包含quality，必须结合上下文阅读。

5.3 Power BI展示与核对

第二周制作了商品、历史评分和评论三个看板页面。商品页展示商品数量、价格和评分，并支持按类别查看；历史页展示评分量和年度变化；评论页展示关键词及情感汇总。老师要求补全交叉核对后，我不仅检查了类别和年份，还核对总体卡片、均值计算、缺失处理、各图数值与筛选后恢复的情况。此前的逐项检查记录保留在结果目录中。

看板中的商品数量应为1,351，价格中位数899，商品平均评分显示约4.09；历史评分数量为7,824,482，平均评分约4.0123；默认情感分类数量为正向1,085、接近中性94、负向7。评论关键词表和情感表属于独立汇总，不能默认二者之间具有逐条关系或会自动互相筛选。静态PDF用于报告展示，实际交互以本地PBIX为准。

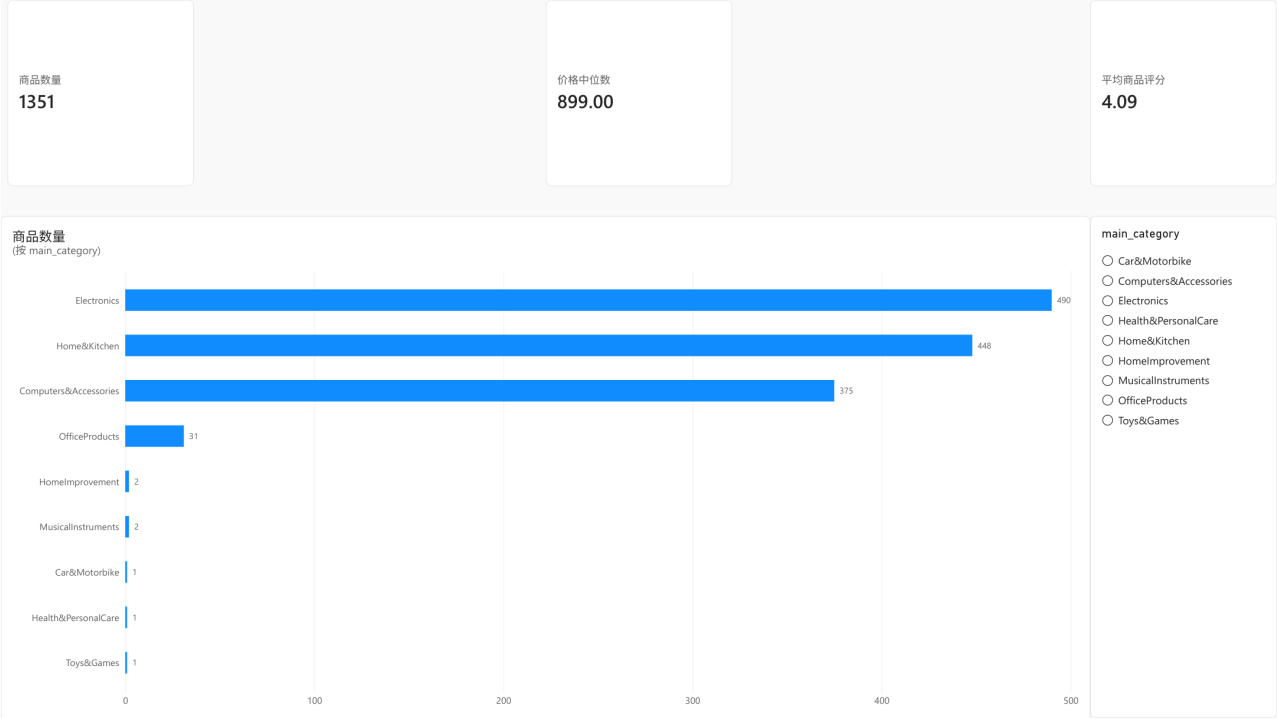


图4 Power BI商品分析页静态展示，交互筛选与恢复已在本地进行检查。

六、情感分析：阈值改变了哪些结论

6.1 基础结果与阈值敏感性

我使用TextBlob对1,186份不同清理文本计算情感得分，得分平均为0.2630，中位数约0.2487。分类规则是得分严格大于阈值归为正向、严格小于负阈值归为负向，其余归为接近中性。采用0.1时，正向1,085份，占91.48%；接近中性94份，占7.93%；负向7份，占0.59%。这些比例描述算法对整格文本的分类，不是消费者满意率。

老师指出结果对阈值敏感后，我进一步比较多个阈值。阈值为零时，正向占98.06%；提高到0.2后，正向降为775份，占65.35%，接近中性增加为409份。仅从0.1变到0.2，正向比例就下降26.14个百分点，其中310份正向文本转为接近中性，另有5份负向文本转为接近中性。变化来自规则边界的调整，而不是评

论内容或消费者态度发生变化。

这次比较让我发现，阈值调高以后，一些原来偏正向或偏负向的文本会被划入接近中性，分类比例也会明显变化。我没有独立标注的数据，所以还不能判断哪个阈值最准确。因此，我保留原来的默认阈值，并一起展示其他阈值的结果。这样读者能看到分类规则对结论的影响。如果以后要评价分类是否准确，还需要先准备有明确判断标准的标注样本。

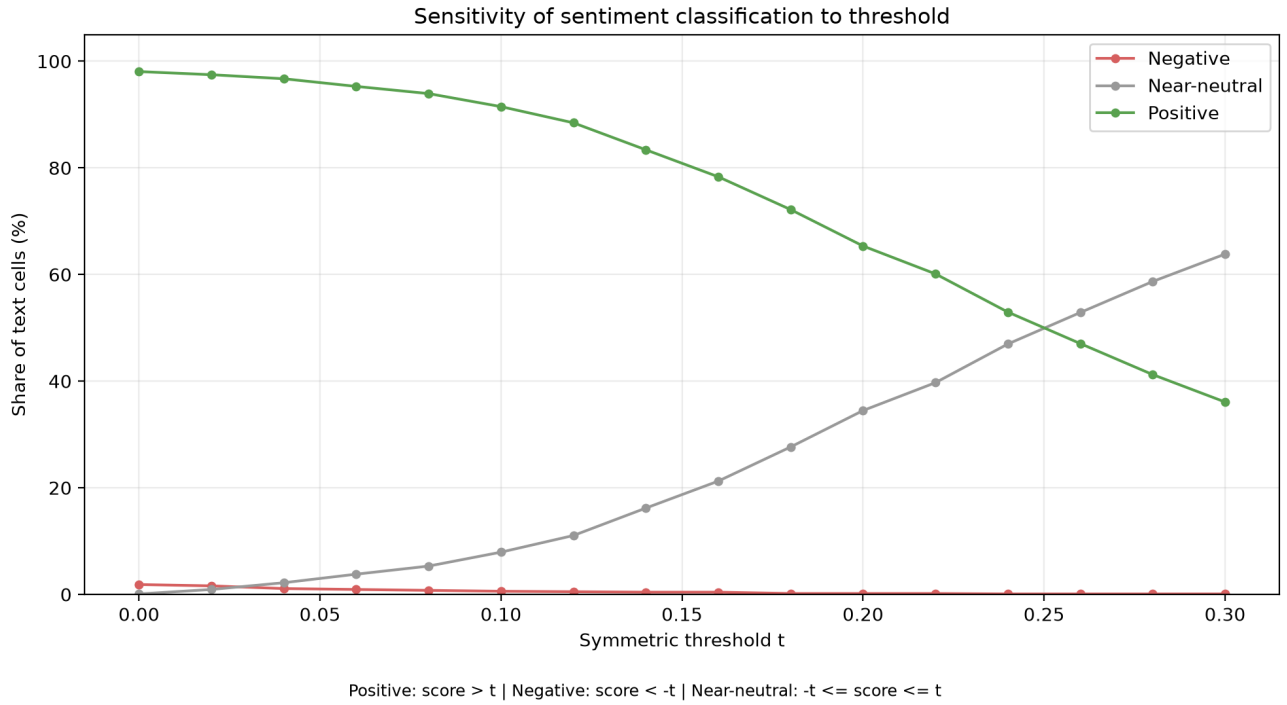


图5 情感分类随阈值变化的结果。比例变化不能解释为满意度变化。

6.2 浮点边界和文本样例的解释

补充分析曾出现正向1,084份、接近中性95份，与原结果相差一条。逐条核对发现，T0208保存的得分是0.10000000000000005，默认读取后变为0.1，因此从严格大于0.1变成等于边界。采用round_trip读取后恢复了原始浮点值，分类与原结果一致。这个问题提醒我，统计口径不仅包括公式，也包括文件保存与读取方式，尤其在阈值附近更需要保持一致。

阅读该样例还发现，正文同时出现不能正常工作、质量差的描述，以及便宜、不错、性价比等正向表达。整格文本把多种意见放在一起，一个轻微正向得分无法表达全部内容。另一个得分等于0.2的样例主要是简短正向评价，阈值提高到0.2后也会进入接近中性。这说明“接近中性”在此是得分区间的名称，不保证文本语义真的没有倾向。

其他样例涉及加热速度、线长、稳定性、售后、噪声和遥控功能，也常出现优点与缺点并存。有的正文夹有非英语内容，算法能利用的信息也可能不同。为了避免把模型标签当作事实，我将情感得分作为寻找阅读对象的辅助信息，具体业务建议仍回到原文。样例阅读有助于解释算法为何改变分类，但样例数量少且不是随机抽样，不能据此计算整个模型的准确率。

七、第三周：主题模型与随机种子比较

7.1 文本准备和初始模型

主题模型希望从较多文本中归纳经常共同出现的词，帮助了解用户讨论的方向。我对1,186份文本进行英文词语提取和停用词过滤，保留至少出现在五份文本、且不超过全部文本百分之八十的词语，词典由11,515个词缩减到2,785个。所有文本过滤后仍有可用词语。预处理规则和词典保存到本地，使后续不同主题数和随机种子的实验使用相同输入。

初始比较三、四、五、六个主题，固定随机种子42。主题一致性分别约0.4021、0.4519、0.4433和0.4197，四主题在这次比较中最高。除了指标，我还查看每个主题的关键词及代表文本。五主题能够单独呈现安装、服务及打印机使用等线索，因此保留五主题作为探索性展示，但没有把它描述为所有条件下的最佳模型。

五主题对应文本数为467、73、330、245和71，分别暂时解释为日常使用与操作体验、清洁设备与空气处理、手机性能与充电配件、音频设备与电子产品体验、安装设置与售后服务。名称来自对关键词及样例的阅读，不是模型自动生成的正式商品分类。一个主题中可能混合不同商品；每份文本也可能涉及多个方向，只是汇总时按最高主题权重分组。

我把主题与情感结果放在一起，比较各组均值和不同阈值下的分类数量。第五组既有安装服务，也有打印机使用反馈，说明主题名称只是大致概括。得分较低不能直接说明商品质量较差，这部分结果主要帮助我找到值得继续阅读的文本，不能直接用来计算投诉比例。

7.2 三个随机种子的补充实验

老师提醒LDA对随机种子较敏感后，我在相同预处理与训练设置下，用42、123、2026三个种子分别训练三至六主题，共得到十二个模型。三主题的一致性均值为0.4051、标准差0.0113；四主题为0.4238、0.0278；五主题为0.4219、0.0187；六主题为0.4515、0.0349。六主题平均分最高，但变化也较大，不能只看均值就认定它同时最稳定。

主题编号在不同模型间没有固定含义，不能直接比较同为“主题一”的词。因此补充实验先依据关键词重合程度进行主题匹配，再计算相似度。三至六主题的平均匹配相似度约为0.4499、0.3696、0.3676和0.3515。该指标关注前十个词的重合，不代表完整语义相同，也不是统计显著性检验；它与关键词和原文阅读一起使用，才能比较全面地认识稳定性。

五主题中，充电线与充电相关词在不同种子下较容易找到对应，而安装和售后主题会与其他主题混合或拆分。原先单次实验中看起来清楚的类别，在另一个种子下未必仍然独立。因此最终报告保留五主题种子42的探索性解释，并同时展示多种子结果，不将它当作稳定的业务标签体系。今后如要自动给商品分配固定标签，需要更明确的标注和独立验证。

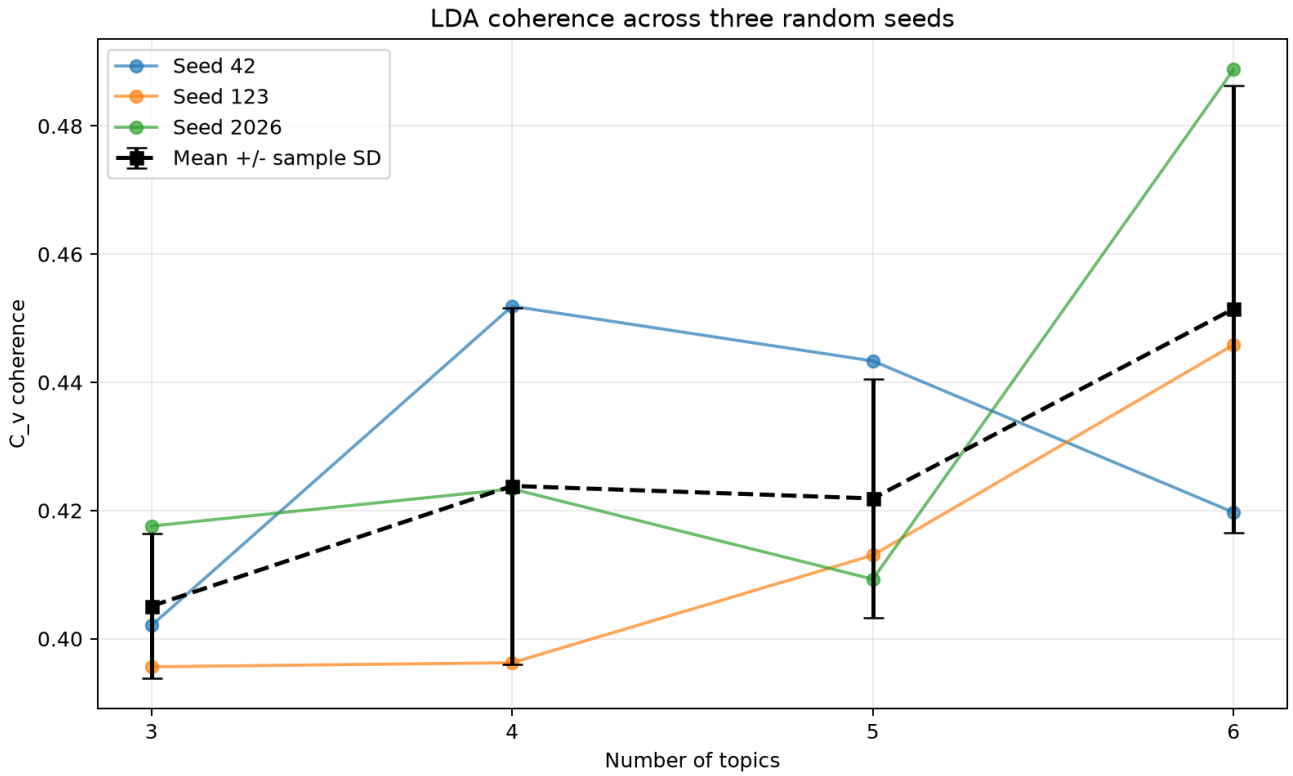


图6 三个随机种子下的主题一致性比较。单次最高值与稳定性并不是同一个判断。

八、推荐实验：数据划分、评分预测和原型

8.1 为什么先筛选活跃用户

历史评分涉及4,201,696个不同用户，平均每人约1.8622条记录，其中约68.59%的用户只有一条评分。直接对这些用户做留出评估，往往没有足够历史记录学习偏好。因此本项目选取至少有二十条评分的用户，得到13,351名用户、452,040条评分和115,394个商品。筛选依据是完整历史记录数，属于回顾性活跃用户样本，结果不能直接推广到全部用户或真实未来的新用户。

候选数据中用户与商品组合没有重复，但矩阵依然非常稀疏，已观察组合只占全部可能组合约0.029341%。大量商品只收到少量评分，这会限制模型估计商品特点的能力。用户活跃不代表消费金额高，记录多也不代表购买次数多，所以报告只称它们为评分活跃用户。这个筛选主要用于建立可运行、可评价的学习实验，而不是商业客户价值分层。

我按用户随机划分训练和测试记录，固定种子42，测试数量向上取整，得到训练356,278条、测试95,762条，分别约占78.82%和21.18%。每位用户至少有十六条训练和四条测试记录。核对结果显示训练测试记录没有重叠，用户商品组合也没有重叠，全部测试用户都在训练中出现。不过随机划分不保证时间先后，因而不能描述为严格的未来预测实验。

测试集中80,286条记录的商品在训练中出现过，另外15,476条、约16.16%的记录对应未见商品。对后者，模型无法使用充分学习到的商品特征。因此除了总体误差，我还分别统计已见和未见商品，避免总体平均值掩盖冷启动困难。训练和测试集一旦确定，就没有根据测试结果反复挑选新的划分。

8.2 SVD与简单基准的比较

评分预测采用全局均值、用户均值和SVD三种方法。全局均值对所有记录给出相同预测；用户均值使用该用户训练评分平均水平；SVD进一步尝试学习用户与商品的潜在特点。本次SVD固定五十个因子、二十轮训练、学习率0.005和正则化0.02，随机种子42。参数事先固定，没有通过测试集反复调参，因此结果是一个基线实验，而非充分优化后的最优模型。

全部测试记录上，全局均值的MAE为0.8929、RMSE为1.1417；用户均值为0.7957和1.0799；SVD为0.7702和1.0529。两项指标均是误差，越低越好。SVD在整体评分预测中优于这两个基准，但在未见商品上，SVD的MAE为0.8888，高于用户均值的0.8699，RMSE则略低。两个指标并不总给出相同结论，需要分别报告。

评分预测误差衡量预测分数与实际评分的接近程度，却不直接回答推荐列表中是否包含用户喜欢的商品。为此，后续增加了前五和前十推荐的精确率、召回率及命中率。评分模型可以把很多分数预测得比较接近，但在少量商品之间的排序上仍然不够好。将两类任务分开评价，是理解后续热门推荐优于SVD的重要前提。

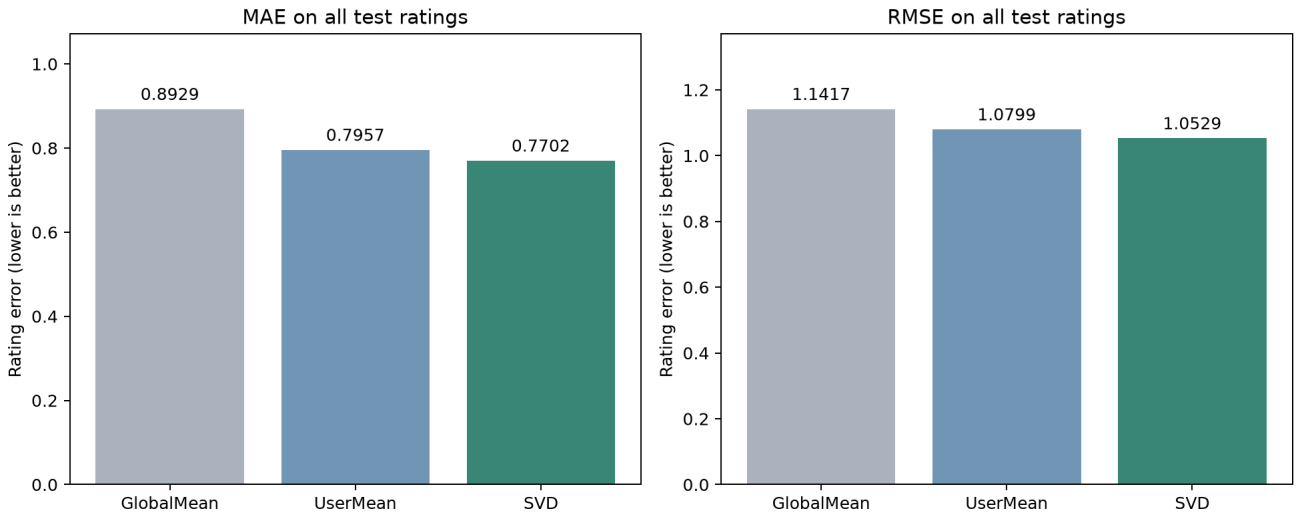


图7 评分预测误差。总体优势不能直接推广为所有商品组或排序任务的优势。

8.3 推荐评估与演示原型

原始排序评估纳入13,212名用户，排除了没有已见测试商品的十五名用户，以及没有已见高评分测试目标的一百二十四名用户。每人的候选集包含训练中已见的测试商品，再加入一百个未评分抽样商品；四分及以上测试评分作为已知相关目标。这里的未评分商品只是没有观察到偏好，不是真实负面评价，候选集也不是整个商品目录。

在这个设置下，热门推荐的Precision@10为0.2536、Recall@10为0.5344、命中率为0.9140；SVD分别为0.1516、0.3155和0.7639。热门推荐排序依据是训练中的评分次数，不是销量。评估使用相同用户和候选集，避免让某个方法获得更容易的测试条件，但候选构造本身仍可能影响结果，所以不能仅凭这一次实验宣布某种方法普遍更好。

原型分别展示已有用户和新用户推荐。对已有用户，先排除训练中已评分的商品，再计算推荐；对新用户，没有历史偏好时回退到热门商品。演示不读取测试集，也不重新训练模型。由于历史商品与商品描

述表重合很少，结果主要展示商品编号及预测或热门度信息，没有为无法匹配的商品编造名称。这个原型证明流程可以运行，不代表已经上线或获得购买转化。

九、热门推荐为什么优于SVD：目标、候选集与长尾

9.1 数据分布和优化目标共同影响结果

老师要求进一步解释热门推荐的优势后，我首先检查训练商品收到评分的数量。训练目录中只有一至四条评分的商品占约84.57%，说明多数商品信息有限。相反，评分次数最多的前百分之十商品，占训练评分记录的55.52%，占已见商品高评分测试记录的63.65%。测试目标本身集中在较热门商品，因此按热门度排序较容易命中这些已观察目标。

SVD的学习目标主要是拟合评分，不是直接最大化前十推荐召回率。高评分目标是否排在前面，还受到用户和商品偏置、稀疏性及候选竞争的影响。分组结果显示，商品训练评分较多时，SVD的误差优势更加明显；而只有一条或二至四条评分的商品中，SVD的MAE略差于用户均值，虽然RMSE稍好。这支持信息稀疏会影响学习效果的解释，但不是对模型内部机制的完整因果证明。

这让我理解了为什么SVD评分预测误差较低，推荐命中却不如热门方法。两项实验回答的问题不同：前者看分数预测得准不准，后者看用户已知喜欢的商品能否排进前几名。在当前数据和候选集设置下，热门商品更容易被命中。因此，我没有简单地把SVD判断为“没用”，而是继续检查候选集和长尾商品，看看两种方法各自有什么表现。

9.2 固定用户后的候选集对照

为检查候选集的影响，我固定两千名共同用户和原模型，比较等概率抽样一百件、按热门程度加权抽样一百件、等概率抽样五百件三种设置。额外候选中的平均头部商品比例，在等概率一百件时约10.02%，加权一百件时升至55.37%。这意味着加权设置引入更多热门竞争商品，热门推荐不再容易仅凭目标商品比随机长尾更热门而命中。

在等概率一百件设置中，热门与SVD的Recall@10分别约53.05%和31.83%，差距21.22个百分点；加权一百件时分别约12.01%和11.92%，差距缩小到约0.08个百分点；等概率五百件时分别约30.24%和15.31%。候选数量增加后竞争更强，两个方法都更难命中。不同设置的分数不应脱离候选条件直接比较，更不能把抽样指标称为全目录推荐效果。

这些结果表明，原来的热门优势与候选构造密切相关，但不能证明加权抽样就还原了真实曝光。实际平台会受搜索、广告、库存、地区和既有推荐影响，简单按评分次数加权只是压力测试。本次也没有多个独立抽样重复或显著性检验，所以不能把接近的两个分数解释为方法等效。报告保留实验条件和样本数量，让结论停留在数据能够支持的范围内。

9.3 长尾与覆盖揭示不同取舍

项目将训练评分次数排名前百分之十定义为头部，其余定义为长尾。等概率一百件、推荐十件时，SVD的长尾召回约11.03%，热门推荐约0.89%；SVD的目录覆盖约11.92%，热门约7.92%。这说明SVD在该实验中能够推荐并命中更多长尾目标，虽然整体召回较低。更广覆盖也不自动代表更高质量，还需要同时看命中情况和用户实际反应。

整体召回按用户平均，而长尾召回按所有用户的长尾命中总数除以相关长尾目标总数计算，两者口径不同。目录覆盖则用推荐过的不同商品数除以训练商品目录数，不能与推荐列表中的长尾占比混为一谈。将这些指标分别列出，能够说明一种方法的推荐是否集中、有没有触达较少被评价的商品，而不是用一个综合分数隐藏各方面的取舍。

结合这些结果，我认为热门推荐可以保留为比较基准，也可以用于没有历史记录的新用户。如果更希望用户发现较少被评价的商品，就还要看长尾召回和商品覆盖；如果主要任务是预测评分，就要看预测误差。以后尝试融合模型或调参时，应另外准备验证集，保留测试集作最后检查。目前这些是离线实验结果，还不能说明推荐能增加多少实际收入。

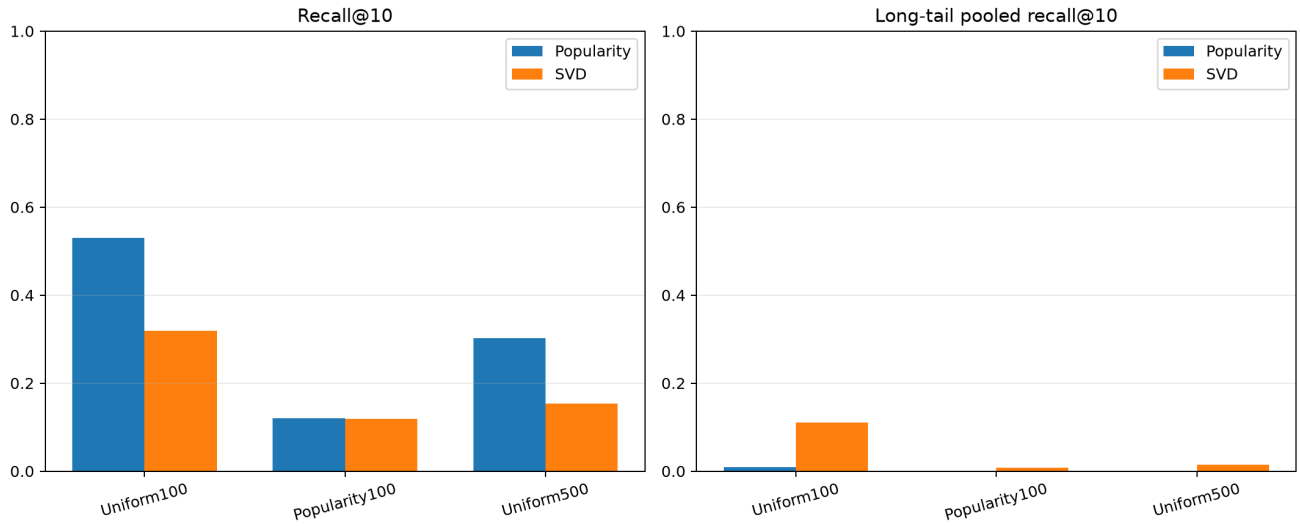


图8 相同用户下的候选集对照与长尾表现，展示热门推荐优势如何随评估条件变化。

十、第四周：从低评分筛选到具体商品证据

10.1 筛选规则与核查队列

第四周以每商品一行的1,351个商品为起点，采用评分低于四分、评分人数至少一百的探索性规则。先区分缺失或异常值，再区分关键字段差异，得到300个可以进一步阅读评论的商品。其余分为不被当前规则选中的1,009个、缺失或异常的3个、低评分但评分人数较少的34个、需先核对关键差异的5个。各组数量与输入总数一致。

一百条评分不是保证代表性的科学界限，因此又比较五十、一百和五百三个门槛。排除关键差异后，待阅读商品分别为315、300和232个。门槛越高，清单越短，但也可能遗漏评分较少的新商品。本次保留一百作为工作量与信息量之间的简单选择，同时保存其他门槛结果，不把某个门槛写成唯一合理标准。

在300个商品中，按评分从低到高、评分人数从高到低及编号排序选取十五个阅读对象。这是有目的的低评分样例，不是随机抽样。通过第一周保留的原始行号与商品编号回到amazon.csv提取对应正文，十五个商品全部匹配成功，正文均非空。商品介绍单独保留，因为商家描述不能直接当作用户反馈；完整正文留在本地，最终交付主要保留归纳结果和索引。

两款PTron手表的正文在统一空白后完全相同，十五个商品实际对应十四份不同文本。汇总时重复正文只算一次，但商品行动映射仍保留两个商品编号，便于后续分别核查。这既避免重复证据放大，又不丢失具体商品。相同正文并不能证明两种颜色质量相同，也不能用于比较哪款投诉更多；它首先提示数据记录存在共享内容。

10.2 阅读中出现的具体问题和不同意见

便携榨汁杯样例中出现动力不足、漏液、续航短的反馈，但也有用户认可制作软质水果奶昔和蛋白饮品的效果。因此建议首先记录食材、装料量、充电条件和工作时间，检查问题是否能够复现，再明确适用场景。不能仅凭“搅拌不够好”就断定所有用途都失败，也不能因存在正向评价就忽略漏液和续航线索。某款评论提到五星返现，需要单独核实，不能直接写成已确认事实。

两类遥控器反映了不同问题。7SEVEN样例中既有按键或兼容性反馈，也有对语音和指针功能的期待，而当前名称已注明不支持这些功能。现有快照无法确认过去页面内容，所以应分别核查实际故障和购买预期。LRIPL样例则更多涉及配对、断连、语音表现及按键手感，同时也有正常使用反馈，适合补充首次配对指引并按设备型号进行测试。

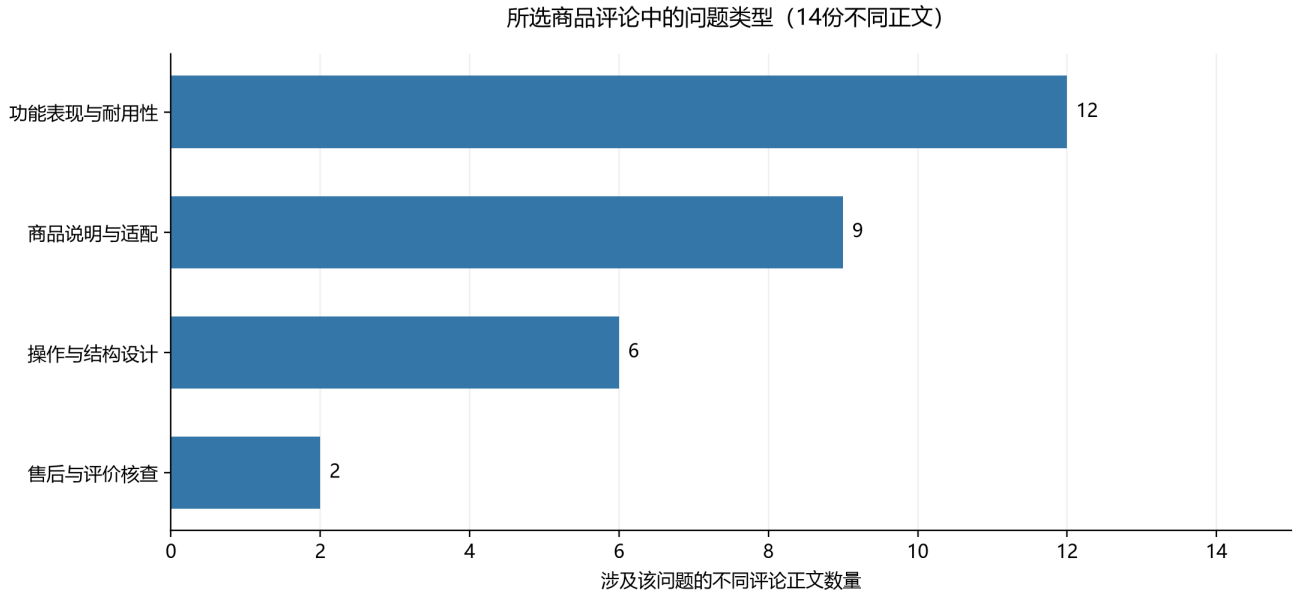
手持缝纫机的评论强调上手和收针打结困难，也认可临时修补与便携性；键盘膜既被反馈偏大，也被反馈偏小，说明不同键盘的适配可能比单一尺寸标签更重要。封口机和打奶泡器涉及按压、电池盖、加热或动力表现，正反反馈并存。这些例子说明，低评分线索可能涉及产品功能、操作说明、结构设计或适用范围，不应全部归结为同一种质量问题。

过滤器样例包含接口脱落、出水量下降及对过滤效果的疑问，也有安装方便的反馈。评论中用TDS数值判断饮水安全的说法不能作为项目检测结论。取暖器样例中有运行故障和保修等待时间的陈述，也有正常工作的评价，对使用时长的提示应以正式说明为依据。切菜机正文较短，主要是充电后不工作和卡住等反馈，缺少明确正向意见，但仍需测试而非直接下结论。

10.3 问题归纳与数量解释

阅读后将问题归为功能表现与耐用性、商品说明与适配、操作与结构设计、售后与评价核查四类。十四份不同正文中，分别有十二、九、六和两份涉及这些方向，对应85.71%、64.29%、42.86%和14.29%。同一正文可以同时涉及多个问题，因此四项数量可以重叠，比例不要求加总为百分之百，也不能解读为全部商品的问题发生率。

这些分类是基于阅读整理的固定样例记录，不是新训练的自动问题识别模型。每个商品同时保存反馈归纳、不同意见、建议措施和核查重点，确保报告不会只选择负面句子。图表用于展示样例中哪些方向更值得关注，具体决策仍需回到商品和使用条件。后续若扩大样本，应重新阅读和检查，而不是把现有十五条配置套用于其他商品。



注：15个商品对应14份不同正文；同一正文可归入多个问题类型。
样例按低评分规则选取，图中数量不代表全部商品的问题发生率。

图9 十四份不同正文的问题类型汇总。允许多标签，仅描述所选低评分样例。

十一、业务行动建议与后续观察方式

我把前面的评论阅读结果整理成四项行动建议，并建立商品与行动对应表，共有三十条关联。有些商品需要同时检查功能、说明和操作方式，所以一件商品可以对应多个行动。我按反馈内容给出了建议处理顺序，方便说明哪些问题可以先核查。这里的顺序是我的分析建议，并不是模型计算的风险分数，也不代表商家已经安排人员执行。

第一项是核查主要功能和故障反馈，涉及十三个商品、十二份不同正文。建议针对充电、续航、连接、密封或运转表现建立简单测试清单，记录相同条件下问题是否复现。过程上可以观察已完成测试项数占计划项数的比例。若未来获得订单和售后记录，再比较同类问题售后申请率，并统一销售批次、观察窗口和跟踪时长，避免用不同口径的数据比较改善。

第二项是补充适配范围与功能说明，涉及九个商品。可先核对正式规格和现有页面，补齐支持型号、实际尺寸、不支持的功能、适用食材及操作限制。过程指标可以使用已核实并补齐的说明项占计划项的比例。后续若有客服数据，可比较每百笔订单中的适配或功能咨询次数，但需要保持咨询分类一致。说明完善是否带来转化提高，需要订单和曝光数据才能判断。

第三项是完善操作指导并检查使用不便，涉及六个商品。针对配对、穿线、打结、封口等步骤制作示例，对电池盖、按键和固定结构分别检查。使用测试可以记录相同任务下成功完成的人数占总测试人数的比例，并控制测试条件。教学说明能否解决问题，与结构本身是否需要调整是两个不同问题，不能只通过增加说明来替代必要的产品检查。

第四项是核实售后流程和评价相关说法，涉及两个商品。售后部分可以记录首次响应时间、结案时间和未结案数量，评价相关事项则记录材料和核查结论，二者不合成一个分数。评论中的等待天数或返现说

法只是待核实线索。项目没有实际工单，也没有执行这些措施，因此基线和目标值均保留为待补充，避免编造改善百分比。

回看前面的分析，我觉得价格表、主题模型和推荐实验也都有各自的用处。价格表帮助比较同类商品；主题模型帮助快速找到评论讨论的方向；推荐实验让我看到不同方法的优点和不足。把这些结果整理成建议时，仍然需要结合具体商品和评论。完成这一步后，我更能理解分析报告为什么既要给出建议，也要解释建议是怎么得来的。

十二、工程整理、复现验证与学习总结

12.1 工程如何从逐步脚本变成可维护目录

前期为了学习和排错，代码按一至四十三步保存。第四周整理时，移除了首次预览、重复控制台检查、临时环境检查和单独的浮点排错脚本，共五个；保留三十八个产生正式结果或支撑实验的任务。原浮点问题改为回归检查，避免删除排错脚本后又失去关键边界验证。另删除候选集比较中未使用的变量，没有为减少文件数量而删掉具有独立分析价值的实验。

新工程使用统一入口run.py，既能运行单步，也能按准备数据、探索分析、主题模型、推荐实验和商品业务分析分组执行。路径设置集中处理，可以指向原工程的数据目录，继续使用原有虚拟环境。任务在独立进程中运行，模块导入不会自动读数据或训练。这样既保留了逐步学习的便利，也减少了全局变量混用和工作目录变化导致的路径错误。

情感分类边界集中在公共模块，商品阅读记录与行动规则从计算代码中提取到JSON配置。配置内容保留研究记录的性质，不能被误认为通用分类器。工程还包含运行说明、代码去向清单、依赖文件和测试。数据、模型和数据库留在本地，不放入老师要求的交付压缩包；结果表、图和必要配置保留，便于检查结论依据。

12.2 已完成的验证及其范围

整理后首先进行了语法和导入检查，并对严格阈值、浮点往返读取和重复文本计数进行回归测试。使用已有样例重新运行第四十二、四十三步，四张结果表与原结果逐列逐值一致。随后在原Windows环境运行检查，确认Python为3.13.5，所需软件包与数据路径存在，四项回归测试全部通过。新增确认的依赖版本包括wordcloud 1.9.6和scipy 1.18.1。

最后在原环境执行第四周完整任务组，即第四十至四十三步。结果仍为1,351个输入商品、300个待阅读商品、十五个样例、十四份不同正文，四类问题正文数为十二、九、六、两份，四项行动和三十条商品行动关联。这验证了重构后的入口、路径、配置与第四周计算能够衔接，并保持原结果。它不意味着前三周所有训练和全量清洗已在新工程中重新运行。

前三周的数据检查、模型训练和补充实验结果已经保存，我在结项时将这些结果统一整理，并核对了关键数字。本轮工程验证重点检查代码整理后是否还能正常调用，以及第四周输出是否与原来一致，没有再次运行前三周全部清洗和训练。以后复现时，需要准备相同的数据、依赖和参数。这也让我认识到，保存代码之外，运行说明和实验配置同样重要。

12.3 四周学习收获与项目完成情况

通过第一周工作，我学会了检查文件结构、保留编号、分批读取和核对记录数。第二周让我认识到，图形不仅需要显示正常，还必须使用正确分母、单位和统计粒度；老师提出的类别拆分和交叉核对，使报告从描述总数转向解释差异。第三周最重要的收获是学会比较基准和追问结果条件，而不是认为用了机器学习就一定更好。

第四周进一步把分析连接到具体商品和行动。阅读正文时，我发现一个低分商品可以同时有认可和抱怨；一个较高的情感得分也可能包含明确的功能问题。因此，数据分析需要在汇总与细节之间反复核对。代码整理则让我意识到，可复现不仅是保留脚本，还包括清楚的目录、运行顺序、参数、输入要求和必要检查。

截至本报告整理时，四周任务均已完成。除了各周分析结果，我已经整理好最终报告、总结PPT和第四周周报，完成了GitHub工程整理与上传，并录制了演示视频，用来介绍分析流程、看板和模型结果。通过整理这些材料，我也重新检查了各部分之间的联系。项目提出了可以继续核查的商品问题和改进方向，实际整改及效果评估需要后续业务数据支持。

回顾这四周，我从不熟悉数据处理，到能够完成清洗、画图、尝试模型并解释结果，学到了不少以前只在书上见过的内容。最开始遇到报错时，我往往不知道从哪里看；现在会先检查路径、字段、数据类型和记录数，再逐步定位问题。我也开始习惯追问平均数用了什么分母、模型比较是否公平、评论能否支持建议。这些具体的检查习惯，是我这次项目中最实用的收获。

结果依据与文件索引

数据质量

第一周实验报告及reports/week1/；week2/tables/data_dictionary.csv、missing_values_summary.csv、anomaly_checks_summary.csv。

商品价格与评分

week2/revision/tables/category_price_summary.csv、category_rating_summary.csv；week2/tables/product_discount_groups.csv。

评论与情感

week2/tables/review_text_structure_checks.csv、review_length_rating_correlation.csv；week2/revision/tables/sentiment_threshold_sensitivity.csv、sentiment_transition_0.1_to_0.2.csv。

看板核对

第二周Power BI导出PDF与week2/revision/tables/powerbi_validation_checklist.csv；交互检查依据本地操作记录。

主题模型

week3/tables/lda_candidate_metrics.csv、topic_sentiment_summary.csv；week3/revision/tables/lda_seed_summary.csv、lda_seed_topics.csv、lda_seed_topic_alignment.csv。

推荐实验

week3/tables/recommendation_split_summary.csv、recommendation_rating_metrics.csv、recommendation_topn_metrics.csv；week3/revision/tables/recommendation_head_concentration.csv、candidate_sampling_metrics.csv、candidate_sampling_scope.csv。

第四周商品分析

week4/tables/product_review_selection_summary.csv、product_review_reading_list.csv、product_review_evidence_index.csv、product_review_actions.csv、product_review_issue_summary.csv。

业务行动与工程验证

week4/tables/business_action_plan.csv、business_action_product_mapping.csv；docs/code_changes.csv、docs/validation.md及2026年11月1日Windows运行记录。

图表沿用对应实验的输出；本报告没有重新计算全量历史评分或重新训练模型。文件路径均以整理工程中的reports为参照。老师提供的项目任务说明和个人四周计划用于确定工作范围。

附录：生成式AI使用情况说明

在这次四周项目中，我使用了ChatGPT等生成式AI工具，帮助理解不熟悉的方法、处理编程问题，以及整理报告和演示材料。AI参与了部分代码和文字草稿的生成，也提供了分析思路、修改建议和排版支持。以下说明我与AI在项目中的主要分工。

1. 代码编写与问题处理

我在本地搭建环境、运行程序，并根据运行结果逐步推进任务。遇到不理解的报错、数据处理方法或模型评估问题时，我会向AI提问。AI提供了代码示例、部分脚本和修改建议，帮助我定位错误、调整程序及整理工程。我结合实际运行输出检查记录数、字段和结果是否一致，因此代码部分包含AI辅助编写和纠错的内容。

2. 数据分析与可视化

我完成了本地数据处理操作和Power BI看板制作，并核对筛选后的指标与Python统计结果。分析过程中，我结合老师的反馈提出修改需求，与AI讨论情感阈值、主题模型随机种子、推荐候选集及长尾商品等问题。Python统计和绘图脚本也使用了AI辅助，报告中的数值以实际运行结果为依据。

3. 报告与演示材料

每周报告、最终报告和演示文稿根据项目任务、我的运行结果、学习体会以及老师的反馈整理。我提供进度、结果和修改要求，参与内容取舍与核对；AI协助梳理结构、形成部分文字草稿、解释实验结果，并进行语言润色和排版。最终材料经过我检查和修改，演示视频由我录制。

4. 使用体会与结果边界

AI帮助我跨过了一些初学阶段的困难，但它的建议仍需要结合数据和实际运行结果判断。例如，我通过反复运行和核对，修正了情感得分读取精度带来的分类差异，也根据补充实验调整了对推荐模型的解释。我在报告中保留了数据和实验的限制，没有把尚未执行的业务建议写成已经取得的改善效果。通过这次项目，我逐步理解了各步骤的作用，也认识到不能仅凭AI给出的解释就直接下结论。